

个人信息

叶笑天

手机/微信: 15103216103

E-mail: xiaotian.ye.mail@gmail.com

Homepage: <https://xiaotianye.me>

研究方向: 大语言模型、知识/记忆机制、知识编辑、Unlearning、可解释性、安全对齐

教育背景

北京邮电大学 本科 - 计算机科学与技术

2022.09 – 2026.06

- 综合绩点: 92.32/100, 3.83/4.00
- 课外活动: ICPC程序设计竞赛集训队成员（北京邮电大学程序设计校赛新生赛金牌）。
- 主要课程: 机器学习（95）、算法设计与分析（98）、数据结构（97）、Python 程序设计（99）、矩阵论（99）、程序设计基础（98）、计算机系统（95）、大数据技术（97）、操作系统（94）等。

荣誉与奖项

2025 CCF 优秀大学生（中国计算机学会颁发，2025年全国共95名本科生入选，每所高校最多提名四人）

2023 ACM-ICPC 国际大学生程序设计竞赛（济南站）亚洲区域赛银牌

2023 CCPC 中国大学生程序设计竞赛（桂林站）全国银牌

2023 全国大学生英语竞赛（决赛）全国一等奖

2023 CCCC-GPLT团体程序设计天梯赛 全国总决赛 个人三等奖

2023 北京邮电大学 三好学生

论文发表与在投稿件

[Google Scholar](#) · [Semantic Scholar](#) · [DBLP](#)

引用数: 129 h 指数: 5 i10 指数: 3 — Google Scholar (2026.6)

重点研究成果（* 共同第一作者）

[1] LLM Unlearning Should Be Form-Independent

[Xiaotian Ye](#), Mengqi Zhang, Shu Wu

发现了LLM Unlearning擦除模型中危险知识任务中，目标知识遗忘效果对训练样本的形式存在强依赖的问题，并提出评估基准 ORT 与形式无关的unlearning方法 ROCr。在安全四大顶会 S&P 审稿阶段获得1,1,2,2的高分（1分为最高），在会议议程中作为首场口头报告论文进行展示。

[S&P 2026 \(Oral Presentation\)](#)

[2] Uncovering Overfitting in Large Language Model Editing

Mengqi Zhang*, [Xiaotian Ye](#)*, Qiang Liu, Pengjie Ren, Shu Wu, Zhumin Chen

探索阻碍模型通过参数修改的编辑方法注入新知识后难以泛化到复杂任务的问题，并发现了知识编辑中的过拟合现象；提出评估基准 EVOKE 与 LTI 方法。在 ICLR 2025 知识编辑子领域中获得排名第二高审稿分数，仅次于当年Outstanding Paper得主 AlphaEdit。

[ICLR 2025 \(Spotlight\)](#)

[3] Knowledge Graph Enhanced Large Language Model Editing

Mengqi Zhang*, [Xiaotian Ye](#)*, Qiang Liu, Pengjie Ren, Shu Wu, Zhumin Chen

提出 GLAME 框架，将知识图谱与图神经网络引入知识编辑领域，通过图方法捕获关联知识注入模型以提升复杂推理任务泛化性。是领域内最早一批研究 LLM 知识更新中复杂推理泛化问题的工作之一。

[EMNLP 2024](#)

- [4] **On the Hidden Costs of Counterfactual Knowledge Training in LLM Unlearning**
Xiaotian Ye^{*}, Xiaohan Wang^{*}, Mengqi Zhang, Shu Wu
EMNLP 2026 在投
- [5] **Uncovering Entity Identity Confusion in Multimodal Knowledge Editing**
Shu Wu^{*}, Xiaotian Ye^{*}, Xinyu Mou^{*}, Dongsheng Liu^{*}, Xiaohan Wang, Mengqi Zhang
NeurIPS 2026 在投
- [6] **Monte-Carlo Interpretability Analysis on Knowledge Editing and Its Generalization Failure**
Xiaotian Ye, ChunYao Yang, Mengqi Zhang, Xiaohan Wang, Dongsheng Liu, Shu Wu
NeurIPS 2026 在投
- [7] **Uncovering Context Reliance in Unstructured Knowledge Editing**
Zisheng Zhou, Mengqi Zhang, Shiguang Wu, Xiaotian Ye, Chi Zhang, Zhumin Chen et al.
EMNLP 2026 在投
- [8] **Spectral Characterization and Mitigation of Sequential Knowledge Editing Collapse**
Chi Zhang, Mengqi Zhang, Xiaotian Ye, Runxi Cheng, Zisheng Zhou, Pengjie Ren, Zhumin Chen
ACL 2026
- [9] **Disentangling Knowledge Representations for Large Language Model Editing**
Mengqi Zhang^{*}, Zisheng Zhou^{*}, Xiaotian Ye, Zhaochun Ren, Zhumin Chen, Pengjie Ren
ICLR 2026
- [10] **UIPE: Enhancing LLM Unlearning by Removing Knowledge Related to Forgetting Targets**
Wenyu Wang^{*}, Mengqi Zhang^{*}, Xiaotian Ye, Zhaochun Ren, Zhumin Chen, Pengjie Ren
EMNLP 2025 Findings
- [11] **KELE: Residual Knowledge Erasure for Enhanced Multi-hop Reasoning in Knowledge Editing**
Mengqi Zhang^{*}, Bowen Fang^{*}, Qiang Liu, Xiaotian Ye, Shu Wu, Pengjie Ren, Zhumin Chen et al.
EMNLP 2025 Findings

科研与实习经历

中国科学院自动化研究所

北京, 中国

科研实习生 — 多模态人工智能系统全国重点实验室 (MAIS)

2023.06 – 2026.06

- 开展大模型知识机制、记忆更新、危险信息遗忘相关研究。导师：吴书、张孟奇。
- **项目一：知识编辑与记忆更新。**围绕大语言模型知识记忆更新的泛化性、鲁棒性与长期稳定性开展系统研究。作为核心贡献者参与三项代表性工作：(1) 针对简单编辑无法捕获关联知识的问题，提出基于知识图谱增强的编辑框架 GLAME (EMNLP 2024)，并 (2) 进一步发现知识编辑在复杂推理场景中的过拟合问题，提出 EVOKE 评测基准与 LTI 方法 (ICLR 2025 Spotlight)；(3) 发现了现有多模态知识编辑方法导致文本模态无关知识受到污染的问题，并提出 EC-Bench 基准和相应缓解策略 (NeurIPS 2026 在投)。此外参与多项相关研究工作，包括大批量知识更新导致模型崩溃缓解方法 (ACL 2026)、通过知识表征解耦保护无关知识 (ICLR 2026)、通过残余知识擦除提升推理场景泛化性 (EMNLP Findings)、及非结构化场景的上下文依赖问题 (EMNLP 2026 在投) 等。
- **项目二：知识遗忘与危险知识擦除。**聚焦大语言模型遗忘、危险知识擦除与安全知识控制中的泛化性问题。主导完成两项工作：(1) 以第一作者提出 LLM Unlearning 的形式无关性问题，发现遗忘效果对训练样本表达形式存在强依赖，构建 ORT 评测基准并提出 ROCR 方法 (S&P 2026 Oral Presentation) (2) 发现基于反事实样本的 unlearning 策略存在的诱导幻觉、知识冲突等缺陷，构造新的评估标准 (EMNLP 2026 待投稿)。同时参与多项相关工作，包括通过移除关联知识提升危险知识擦除的泛化性 (EMNLP Findings)，并将知识擦除视角延伸到记忆更新场景下的复杂推理可靠性提升 (EMNLP Findings)。

- **项目三：知识记忆底层机制可解释性分析。**主导研究大模型内部知识记忆、编辑失败与泛化边界的机制解释。提出基于蒙特卡洛采样的可解释性分析框架，分析知识编辑过程中潜在表征解空间、梯度方向与知识向量分布特性，从表征空间分析通过参数更新注入知识难以泛化到复杂推理任务的原因（NeurIPS 2026 在投）。

个人项目

FoldManusAgent：支持上下文折叠的 Browser + CLI 混合智能体系统

- 针对 LLM Agent 长程任务中的 上下文窗口占用过高 与 推理成本随轨迹增长快速累积 问题，设计并实现 FoldManusAgent，一套支持 Browser + CLI 混合执行的通用智能体框架
- **混合工具执行框架：**实现 Browser-use 与 CLI 的统一工具接口，支持 Agent 在网页交互、信息检索与本地命令执行之间动态切换，实现多环境协同任务执行。
- **持久化记忆：**参考网页端 ChatGPT 的 memory 管理机制，设计持久化用户记忆模块；为 LLM 提供完整 CRUD Memory API，使模型能够自主读写、维护与更新用户偏好信息，实现长期个性化交互能力。
- **工作记忆与上下文折叠：**受 FoldGRPO 中 Context Folding 机制启发，在 Agent Harness 层实现 Branch/Fold 上下文管理机制，支持对长程任务中中间步骤的临时信息进行识别与阶段性摘要压缩，减少 Browser-use 场景中临时中间状态对上下文窗口的持续占用。
- **效率分析：**在自建 Browser-use Agent 测试任务中，任务成功率保持稳定条件下，降低约 30% 上下文Token消耗量，显著降低长轨迹任务推理成本。

学术服务

会议审稿人 ICML 2026, NeurIPS 2026, ACL Rolling Review

专业技能

- **编程能力：**较为擅长 Python、C++ 与 C；熟悉在 Linux 服务器与类 Unix 环境下的程序开发；有丰富的算法竞赛编程经验。熟悉Vibe Coding。
- **机器学习：**熟悉 PyTorch 与 NumPy，以及常用框架如LangChain、LangGraph等；对机器学习及大语言模型的理论与方法有深入理解，尤其是 LLM 知识机制与可解释性领域。了解Agent相关方向进展。了解LLM各个子领域的常见概念。
- **英语水平：**TOEFL BestScore 112 分（阅读 29、听力 30、口语 25、写作 28）；具备较强的学术英语读写能力。

最后更新：2026 年 6 月 26 日